代码说明 • 技术设计 • 复现验证

学习型相位反演技术说明

可微前向 · CNN · two-stage

代码：ml/

依赖：PyTorch、NLopt、NumPy

对齐：主报告 5 帧/Z4Z8Z9/图像 SSE

版本：v1.0 • 2026-11

> *本模块是方法验证：64×64 纯 PSF 代理，不是主报告 256²/15 星的复现；数字不能混表。*

01 定位与数据流

先明确代理模型和主求解器的关系。

表 1-1　口径差异

项	主报告	本模块
网格	256²，过采样 2	64×64，过采样 2
星点	15 颗，叠加	纯 PSF
变量	Z4/Z8/Z9	3 项
优化	40 起点+坐标下降+top3 BOBYQA，maxeval 2000	CNN 初值 + BOBYQA maxeval 120
结果	0.001667 λ	0.00955（方法验证）

代码 1-1　数据流。

```
coeff -> torch pupil + 5 defocus
      -> fft2 -> |.|^2 -> 2x2 binning
      -> CNN -> initial coeff
      -> NLopt BOBYQA -> refined
```

02 可微前向

> 傅里叶光学 + Zernike，全部 torch 可微。

$P=A\cdot\exp(i2\pi\phi)$，$\phi=\Sigma c_kZ_k+d\cdot Z4$；$PSF=|FFT(P)|^2$；2×2 binning。$Z4=\sqrt{3}(2\rho^2-1)$，$Z8=\sqrt{8}(3\rho^3-2\rho)\cos\theta$，$Z9=\sqrt{8}(3\rho^3-2\rho)\sin\theta$。

代码 2-1　前向核心。

```
mask,z4,z8,z9 = zernike_basis(fft_n)
phase = 2*pi*(c4*z4+c8*z8+c9*z9+d*z4)
psf = |fftshift(fft2(mask*exp(1j*phase)))|^2
```

噪声按每帧峰值相对缩放；直接加 1% 绝对噪声会淹没归一化 PSF（峰值 ~$1/n^2$），这是实际修过的 bug。

2.2 采样与归一化

64×64 输出、2× 过采样（FFT 128^2）、2×2 binning。归一化分三套：前向每帧 sum=1；CNN 输入按帧峰值；BOBYQA 目标按 sum。三套不能混，否则精度会无故下降。

2.3 为什么是 64×64

主报告是 256^2/15 星/5 帧；训练 CNN 需要成千上万样本，256^2 的 CPU 训练成本过高。64×64 纯 PSF 保留 Zernike/离焦/FFT 的物理，用于方法验证；结论不外推到主报告。

03 CNN 训练

从 5 帧 PSF 回归 3 个系数。

表 3-1 ZernikeCNN

层	配置
输入	5×64×64
Conv/Pool	16→32→64 通道，3×3
Pool	4×4 自适应
Head	1024→128→3

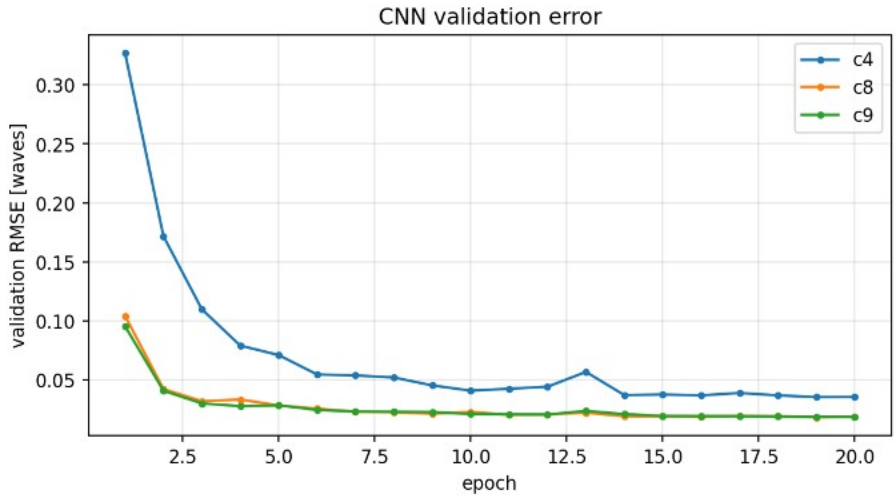


图 3-1 验证 RMSE 随 epoch 下降；c8/c9 约 0.018 waves。

20 epochs、2048 在线样本、batch 64、Adam 1e-3、CosineAnnealing；CPU 约 149 s。验证集 c4/c8/c9 RMSE = 0.035/0.018/0.018 waves。

表 3-2 训练/验证记录

epoch	c4	c8	c9	累计时间
1	0.327	0.104	0.095	9 s
4	0.079	0.033	0.028	30 s
8	0.052	0.022	0.023	59 s
12	0.044	0.021	0.020	88 s
16	0.037	0.019	0.019	117 s
20	0.035	0.018	0.019	149 s

04 传统对比与 two-stage

> CNN 快，传统准但慢；two-stage 取两者。

表 4-1　4 个独立测试样本

方法	c4	c8	c9	波前 RMS	时间
CNN	0.0266	0.0205	0.0165	0.0290	1.1 ms
多起点 LSQ	0.0204	0.0307	0.0075	0.0098	94.8 s

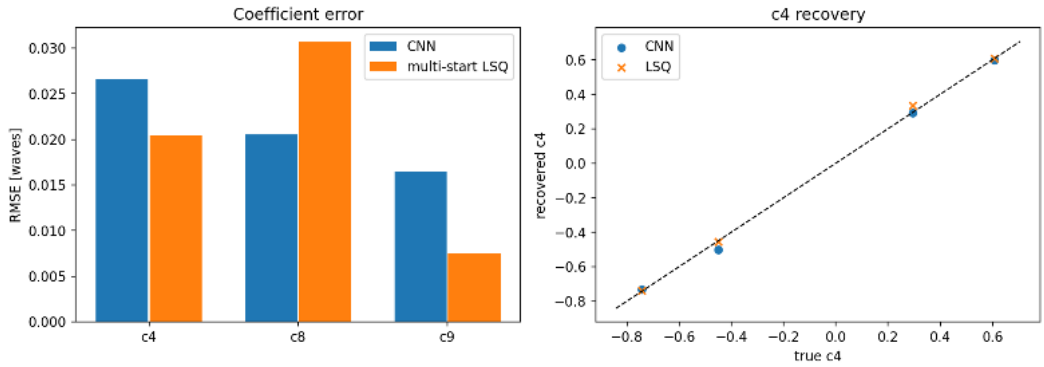


图 4-1　CNN 与多起点最小二乘的系数误差/ c4 恢复。

固定同一个 BOBYQA、只换初值：CNN 初值平均 34 次评估，40 随机起点平均 1823 次；时间 0.226 s vs 13.33 s；精度相同。

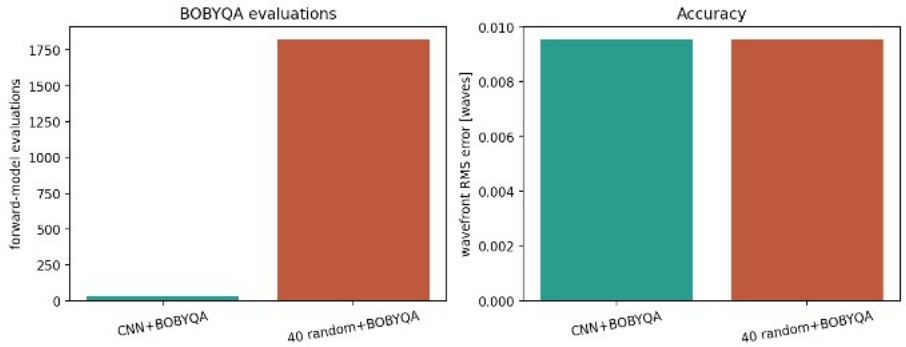


图 4-2　CNN 初值 vs 40 随机起点的评估次数/精度。

口径提醒

two-stage 用 maxeval=120，baseline 是“40 起点×BOBYQA”，不是主报告的“坐标下降+top3”；不能写成主项目已节省 54×。

4.3 传统法的局部极小

c8/c9 有符号/多峰结构；从零起点常落到 c8≈0 的宽局部极小，16 个随机起点才稳定。CNN 的价值是给一个接近真值的初值，而不是保证全局最优；two-stage 仍需要代价/残差兜底。

05 代码、注释与测试

每个脚本做什么。

表 5-1 ML 脚本

文件	职责	注释
phase_torch.py	可微前向	模块 docstring + 物理公式
dataset.py	在线数据/噪声/归一化	数据分布/单位
model.py	CNN	层/输入输出
train_cnn.py	训练/验证/保存	参数/日志
traditional.py	多起点 LSQ	优化器/边界
compare.py	精度/速度对比	指标口径
two_stage.py	CNN+BOBYQA	评估次数

5.2 注释与接口

表 5-2 注释要点

文件	注释内容	边界
phase_torch.py	模块 docstring 写光路/单位；函数写输入形状	64×64 代理
dataset.py	数据分布/噪声/归一化	同分布训练
model.py	层/输入输出	15 万参数
two_stage.py	BOBYQA 参数/评估计数	maxeval=120 实验

ml/tests/test_phase.py 4 项：形状/归一化、梯度非零、波前 RMS、数据集标签；全部通过。

5.1 边界

- 3 - 4 个测试样本，结论是量级；
- 同分布仿真，不是真实望远镜；
- CNN 无不确定度/物理约束；
- 主项目接入前要重新标定/训练。

附录 A 关键源码

代码 A-1　可微前向。

```
def psf_from_coeff(coeff, defocus, cfg):
    mask, z4, z8, z9 = zernike_basis(fft_n, cfg.pupil_radius)
    phase = 2*pi*(c4*z4 + c8*z8 + c9*z9 + defocus*z4)
    pupil = mask * torch.exp(1j*phase)
    psf = |fftshift(fft2(pupil))|**2
    return avg_pool2d(psf, cfg.oversample)
```

代码 A-2　two-stage 对比的评估计数。

```
# two_stage.py: same BOBYQA, different initial guess
x_cnn, nfev_cnn, cost = bobyqa(cnn_prediction, data, ...)
best = None
for k in range(40):
    x, nfev, cost = bobyqa(random_start(), data, ...)
    best = min(best, (x, nfev, cost), key=lambda z: z[2])
```